Relatorio de Entrega - Deep Learning

Atividade: Classificacao de Flores com CNN (5 classes)

Data: 18/04/2026

1. Objetivo

Comparar dois modelos de classificacao de imagens reais de flores: Modelo A (baseline) versus Modelo B (Data Augmentation + Dropout + EarlyStopping).

2. Metodologia

Dataset flower_photos com 5 classes (daisy, dandelion, roses, sunflowers, tulips). Split com validacao e teste, treinamento com metricas de classificacao e analise por matriz de confusao.

3. Resultados Quantitativos

Metrica	Modelo A	Modelo B
Accuracy	0.6099	0.8455
Precision (macro)	0.6091	0.8377
Recall (macro)	0.6221	0.8503
F1 (macro)	0.6043	0.8419
Precision (weighted)	0.6255	0.8518
Recall (weighted)	0.6099	0.8455
F1 (weighted)	0.6069	0.8467

EarlyStopping (Modelo B) - head: epoca 6, fine-tuning: epoca 3, total acumulado: epoca 9

4. Respostas as Perguntas do Enunciado

1. Accuracy isolada pode ser enganosa em classes desbalanceadas; deve-se usar Recall, Precision, F1 e PR-AUC da classe de interesse.

2. Em fraude, falso negativo tende a ter maior custo financeiro direto; falso positivo gera friccao com cliente. A decisao ideal usa matriz de custo.

3. Fashion-MNIST possui confusoes visuais esperadas entre classes parecidas (ex.: shirt/t-shirt, pullover/coat).

4. Modelo A apresentou sinal de overfitting no final; Modelo B generalizou melhor com EarlyStopping.

5. Macro-F1 pondera classes igualmente; Weighted-F1 pondera por suporte. Macro-F1 e melhor para equilibrio entre classes.

6. No sweep opcional de dropout, 0.5 foi o melhor compromisso no seu experimento recente.

5. Evidencias Graficas

loss_a_vs_b.png

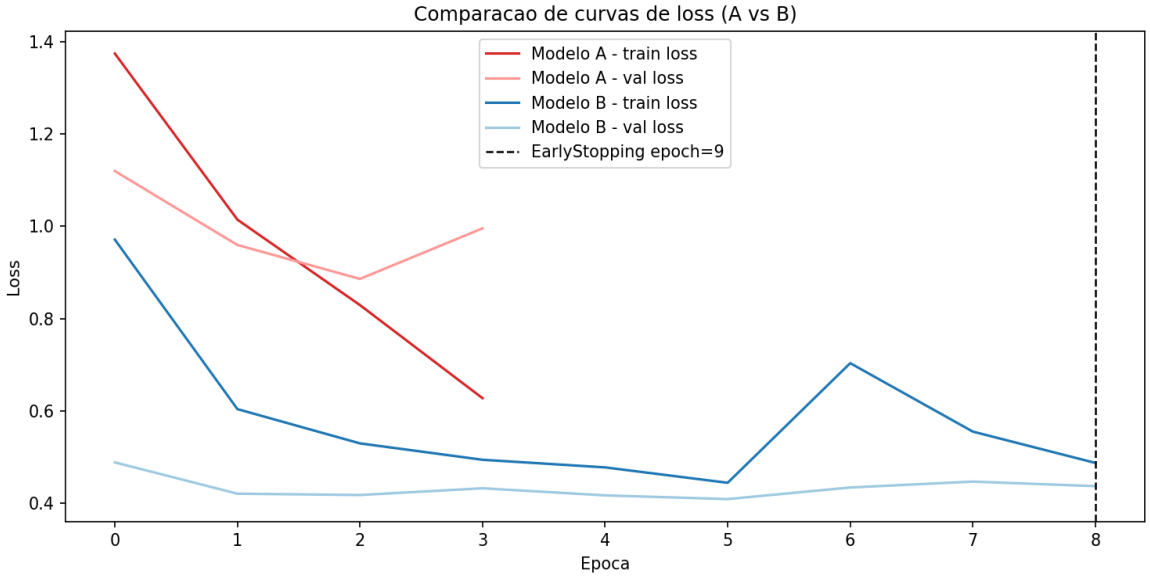

cm_modelo_a.png

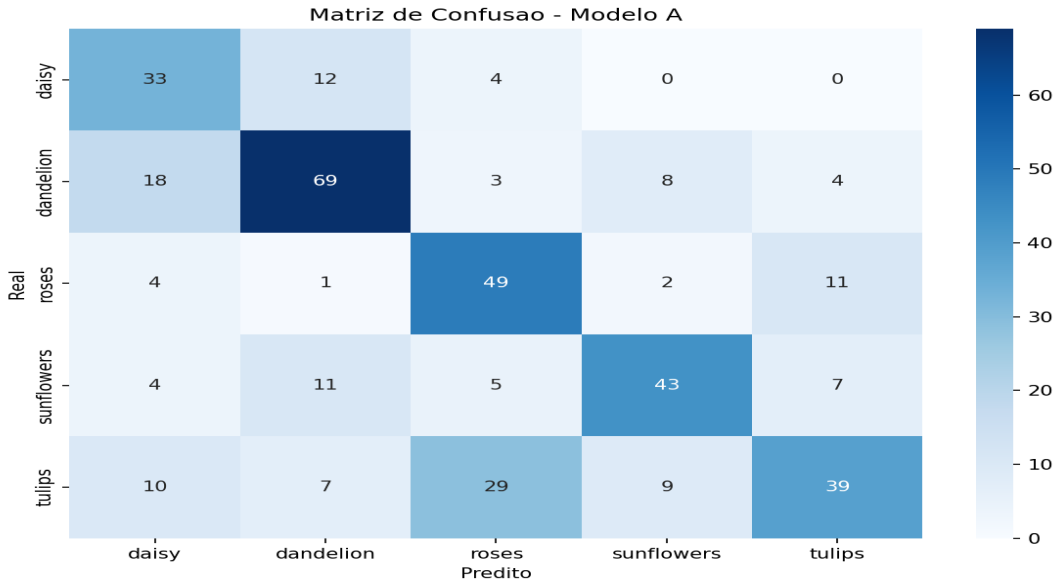

cm_modelo_b.png

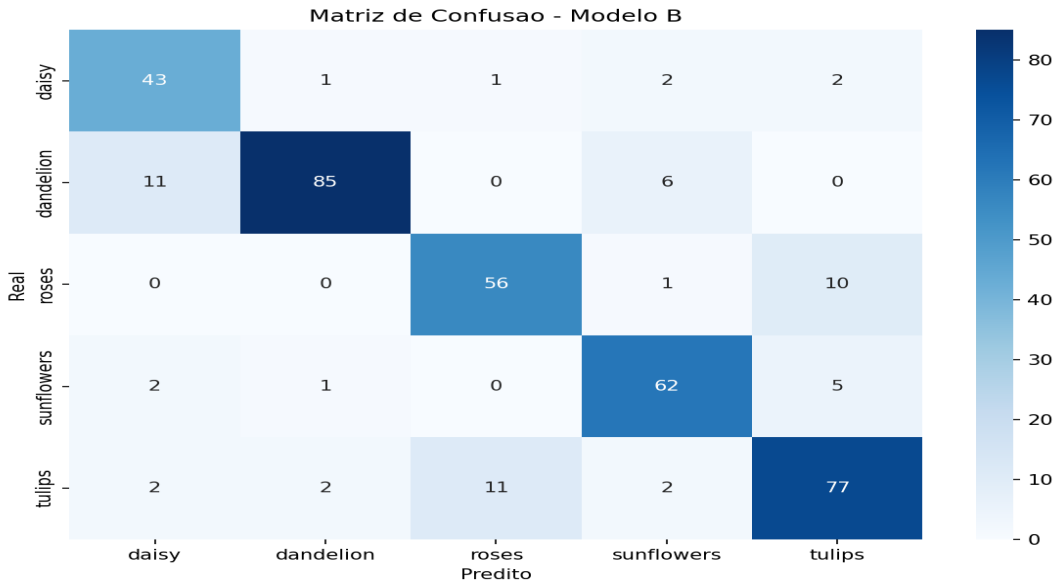

6. Conclusao

O Modelo B superou o baseline em todas as metricas principais (accuracy, macro-F1 e weighted-F1), com melhor capacidade de generalizacao para imagens reais de flores.