

TRANSFER LEARNING COM RESNET50 EM CIFAR-10 E EUROSAT

Gustavo Dutra Telles | Deep Learning | Andre Insardi | Sistemas de Informação

Síntese objetiva para entrega: comparação entre feature extraction e fine-tuning em um domínio próximo e outro distante do ImageNet.

Configuração experimental

Modelo base: ResNet50 pré-treinada em ImageNet. Estratégias: feature extraction e fine-tuning (layer3 e layer4). Otimizador Adam com weight decay = $1e-4$, learning rate discriminativo de $1e-3$ na cabeça final e $1e-4$ nos blocos descongelados, batch size = 64, 10 épocas, CrossEntropyLoss com label_smoothing = 0,1, dropout = 0,3 e early stopping com paciência 3.

Resultados principais


Dataset	Estratégia	Accuracy	F1 macro	Tempo (min)	Treináveis
CIFAR-10	Feature Extraction	76,85%	76,68%	50,41	20.490
CIFAR-10	Fine-tuning	95,03%	95,03%	48,04	22.083.594
EuroSAT	Feature Extraction	80,10%	83,79%	27,69	20.490
EuroSAT	Fine-tuning	98,00%	97,95%	29,00	22.083.594

Análise crítica obrigatória

- 1. O maior ganho do fine-tuning sobre feature extraction ocorreu no CIFAR-10 em acurácia (+18,18 p.p.) e quase empatou em EuroSAT (+17,90 p.p.). Isso acontece porque CIFAR-10 exige mais adaptação semântica das camadas altas, enquanto EuroSAT já se beneficia fortemente dos filtros gerais da ImageNet. As metas do enunciado foram tratadas como orientativas.
- 2. A proximidade entre ImageNet e CIFAR-10 favoreceu bastante a feature extraction, mas o fine-tuning foi decisivo para atingir o patamar superior. Em EuroSAT, a base congelada já foi forte, mas o ajuste fino consolidou a separação entre classes e melhorou a generalização.
- 3. As curvas de loss não mostram overfitting severo. Em CIFAR-10 há leve abertura entre treino e validação; em EuroSAT as curvas ficam ainda mais próximas. As regularizações foram suficientes porque dropout, weight decay, label smoothing e early stopping mantiveram a validação estável.
- 4. As confusões foram semanticamente coerentes: CIFAR-10 confundiu airplane/ship, automobile/truck e cat/dog; EuroSAT confundiu Highway/River, AnnualCrop/PermanentCrop e Pasture/HerbaceousVegetation.
- 5. Descongelar apenas as últimas camadas é eficiente porque preserva filtros universais de borda, textura e forma, enquanto adapta só a parte mais semântica da rede ao novo domínio.




CIFAR-10 | Feature Extraction

Accuracy: 76,85% | F1 macro: 76,68% | Tempo: 50,41 min | Parâmetros treináveis: 20.490




CIFAR-10 | Fine-tuning

Accuracy: 95,03% | F1 macro: 95,03% | Tempo: 48,04 min | Parâmetros treináveis: 22.083.594



EuroSAT | Feature Extraction

Accuracy: 80,10% | F1 macro: 83,79% | Tempo: 27,69 min | Parâmetros treináveis: 20.490



EuroSAT | Fine-tuning

Accuracy: 98,00% | F1 macro: 97,95% | Tempo: 29,00 min | Parâmetros treináveis: 22.083.594

